

| INTRODUCTION TECHNIQUE

FASTR pour les développeurs

Une vue d'ensemble des données, du pipeline et du vocabulaire

CE QU'EST FASTR

Frequent Assessments and System Tools for Resilience — l'approche de la GFF pour l'analyse à cycle rapide et l'usage des données.

EN UNE PHRASE

Un **pipeline de données** qui extrait les registres de santé mensuels de routine d'une base nationale, les nettoie, et les transforme en estimations fiables indiquant si les gens reçoivent les soins dont ils ont besoin.

MODÈLE MENTAL

ETL → valider → transformer → KPI. Les termes de santé reposent sur de l'ingénierie de données standard — ce sont des étiquettes métier, rien de plus.

La forme générale

```

DHIS2 (base source) → Données SIGS (comptages bruts) → Modules FASTR (étapes du pipeline) → Résultats (estimations propres, graphiques, % couverture)
une ligne par formation x indicateur x mois
M1 → M2 → M3
M5 → M6
    
```


- **DHIS2** — la base de production du pays pour les données de santé. Application web + API REST. En lecture seule du point de vue du pipeline.
- **Données SIGS** — ce que nous extrayons : des **comptages de services mensuels** de routine, un nombre par formation, par indicateur, par mois.
- **Modules** — étapes du pipeline. Chacune lit le résultat de l'étape précédente ; les dépendances forment un DAG.
- **Résultats** — des CSV et des graphiques que les équipes de santé utilisent pour décider.

LES DONNÉES

D'où viennent les données : DHIS2

DHIS2 est une plateforme open source que la plupart des pays à revenu faible ou intermédiaire utilisent comme entrepôt national de données de santé de routine — autrement dit la **base de production faisant foi**.

- Chaque clinique et hôpital (une **formation sanitaire**) déclare des chiffres chaque mois
- Les données sont indexées par **formation × indicateur × mois**
- Elles sont extraites via l'**API** de DHIS2 (ou un export CSV) dans une table à plat — les **données SIGS** (`hmis_XXX.csv` , où `XXX` est le code pays)



Une instance DHIS2 — la démo publique (données d'exemple de la Sierra Leone). C'est le type de système d'où les données sont extraites.

Des comptages, pas des pourcentages. Le pipeline ingère des **comptages bruts** — « 152 enfants ont reçu le Penta1 dans cette formation en mars 2024 » — jamais « 92 % de couverture ». Les comptages s'additionnent entre formations et permettent à la détection d'aberrants de travailler sur la magnitude ; les pourcentages, non.

LES DONNÉES

Ce qu'est un « indicateur »

En santé mondiale, un **indicateur** est une variable définie et mesurable servant à surveiller un système de santé – pour suivre la prestation de services, la couverture ou les résultats de santé dans le temps et entre lieux, et pour éclairer les décisions. C'est un substitut standardisé : on ne peut pas mesurer « la santé maternelle s'améliore-t-elle ? » directement, alors on suit quelque chose de dénombrable qui en tient lieu.

Dans les données SIGS de routine, chaque indicateur est un événement de service précis que les formations enregistrent et déclarent chaque mois. (Pour un développeur : voyez-le comme une métrique suivie – un événement nommé et compté, comme un type d'événement en analyse produit.) FASTR se concentre sur un petit noyau d'indicateurs **SRMNEA-N** à fort volume (santé reproductive, maternelle, néonatale, de l'enfant, de l'adolescent + nutrition) :

ANC1

ANC4

Accouchement institutionnel

PNC1

BCG

Penta1

Penta3

Consultations externes

Indicateur	En clair
ANC1 / ANC4	La 1re / 4e consultation prénatale (avant la naissance) d'une femme enceinte
Accouchement institutionnel	Une naissance survenue dans une formation sanitaire
PNC1	Première consultation postnatale (après la naissance)
BCG	Vaccin contre la tuberculose, administré à la naissance
Penta1 / Penta3	1re / 3e dose du vaccin nourrisson 5-en-1
Consultations externes	Visites en ambulatoire – un substitut de l'usage général des services de santé

Choisis pour leur fort volume de déclaration et parce qu'ils tiennent lieu de nombreux autres services rendus lors de la même visite. Les pays ajoutent les leurs par-dessus.

| LE PIPELINE

Ce que font les modules

Chaque module est une étape. Ils s'exécutent **dans l'ordre**, et chacun consomme le résultat des précédents — la → est une vraie dépendance de données.

1 M1 — Évaluation de la qualité des données (EQD)

Validation + détection d'anomalies. Signale les **valeurs aberrantes** (un comptage très éloigné de l'historique propre à la formation) et les lacunes de **complétude** (mois où une formation n'a pas déclaré). En lecture seule — elle étiquette les problèmes, ne change rien.

2 M2 — Ajustement de la qualité des données

L'étape de correction. Consomme les signalements de M1 et **répare** les données — remplace les aberrants, comble les lacunes par des estimations statistiques — pour que les calculs en aval ne soient pas faussés par de mauvaises entrées. Émet le jeu de données ajusté.

3 M3 — Utilisation des services

Analyse de tendance : les services montent-ils ou descendent-ils ? Utilise la régression pour mesurer les tendances et détecter les **perturbations** (ex. une baisse des visites après une coupe de financement ou un choc).

4 M5 → M6 — Estimations de couverture

La **couverture** = la part des gens qui *avaient besoin* d'un service et l'ont effectivement reçu. Exemple : 8 000 nourrissons d'un district ont reçu le vaccin contre la rougeole, et environ 10 000 nourrissons y vivent → ~80 % de couverture.

Le chiffre du haut (8 000) est un **comptage** que nous avons déjà. Le chiffre du bas (10 000 — la **population cible**) n'est *pas* dans les données : aucun système ne déclare « combien de nourrissons existent ». Estimer ce dénominateur est le plus difficile, et c'est tout le travail de M5 — il le dérive des données SIGS, d'enquêtes ménages et de projections de population de l'ONU. **M6** calcule ensuite le % de couverture et comble les années entre les enquêtes.

M1 valider → M2 corriger → M3 tendances → M5/M6 couverture. (M4 est l'ancien module de couverture, remplacé par M5+M6.)

| RÉFÉRENCE

Décodeur de jargon

Terme	Signification
DHIS2	Base nationale de santé d'où le pipeline lit (dotée d'une API)
SIGS / HMIS	Système d'information de gestion sanitaire — les données de routine elles-mêmes
Formation (sanitaire)	Une clinique ou un hôpital — une source de déclaration
Indicateur	Un événement de santé compté (une métrique)
Comptage / volume	Nombre brut d'événements. L'entrée. Jamais un %
Zone administrative	Niveau géographique : national → région → district → aire de santé
Valeur aberrante	Un comptage invraisemblablement élevé face à l'historique propre à la formation
Complétude	Si une formation a déclaré, ou non, pour un mois donné
Couverture	% de la population cible ayant reçu un service (un KPI)
Dénominateur	La population cible (ex. toutes les femmes enceintes) — estimée, non comptée
SRMNEA-N	Le domaine de santé : santé reproductive, maternelle, néonatale, de l'enfant, de l'adolescent + nutrition
Perturbation	Une baisse significative du volume de services (choc, coupe de financement, etc.)
Module (Mx)	Une étape du pipeline

Pour aller plus loin

- **Docs de méthodologie** — une page par module du pipeline (EQD, ajustement, utilisation des services, couverture), avec toute la logique et les paramètres

Lire : FASTR-Analytics.github.io/fastr-resource-hub · Source : github.com/FASTR-Analytics/fastr-resource-hub

- **Code source des modules du pipeline** — chaque module (`m001` ... `m006`) fournit un `definition.json` (entrées, paramètres, sorties) et un `script.R` (la logique)

github.com/FASTR-Analytics/modules